

Discente: Luis Felipe do Nascimento Moura

Docente: Kelson Romulo Teixeira Aires

Universidade: Universidade Federal do Piauí (UFPI)

Disciplina: Visão Computacional

Experimentos com Fluxo Óptico:

Farneback, Horn-Schunck e Lucas-Kanade

Resumo

Este relatório apresenta os resultados dos experimentos realizados com os métodos de cálculo de fluxo óptico **Farneback**, **Horn-Schunck** e **Lucas-Kanade**, utilizando o vídeo [videoVisao.mp4](#). Foram implementadas técnicas de segmentação e clustering, com o objetivo de demonstrar o desempenho e a eficácia de cada método em detectar movimento e segmentar objetos em vídeos. O uso do algoritmo de clustering **KMeans** foi aplicado a fim de agrupar os objetos em movimento detectados em cada técnica.

Objetivo

O objetivo deste relatório é apresentar:

- Resultados das aplicações dos métodos **Farneback**, **Horn-Schunck** e **Lucas-Kanade**.
 - Segmentação e detecção de movimento com clustering utilizando o KMeans.
 - Análises e comentários sobre os resultados obtidos, discutindo a precisão e desempenho de cada técnica.
-

Materiais e Métodos

Ferramentas Utilizadas

- **Linguagem:** Python 3.x
- **Bibliotecas:** OpenCV, Numpy, Scikit-Learn
- **Vídeo:** [videoVisao.mp4](#)

Métodos de Cálculo do Fluxo Óptico

1. **Farneback**
2. **Horn-Schunck**
3. **Lucas-Kanade**

Resultados

Farneback

Segmentação do Fluxo Óptico:

Os resultados mostram a segmentação dos objetos em movimento detectados no vídeo. Foram aplicados o algoritmo de clustering KMeans e a segmentação personalizada com a máscara em que objetos móveis foram atribuídos a diferentes clusters com cores distintas.

Observações:

- A segmentação identificou a maioria dos objetos em movimento com clareza, identificou movimentos diferentes em diferentes partes do objeto principal.

Horn-Schunck

Segmentação do Fluxo Óptico:

O método Horn-Schunck apresentou segmentação contínua e suave, demonstrando boa precisão na detecção dos movimentos. A segmentação foi baseada em gradientes e diferenciação espacial.

Observações:

- Os clusters de movimento foram segmentados de maneira suave e contínua.
- A segmentação tendeu a ser menos sensível a ruídos ao ajustar o threshold de movimento, mas a computação é um pouco mais lenta em comparação ao método Farneback.

Lucas-Kanade

Segmentação do Fluxo Óptico:






O método Lucas-Kanade mostrou uma abordagem específica ao detectar pontos-chave no vídeo, identificando objetos móveis através do agrupamento das características detectadas com o KMeans.

Observações:


- Esta abordagem se destacou por sua precisão ao capturar os pontos de movimento individualmente.
- Acabou identificando objetos parcialmente estáticos (pequenas vibrações por conta do ambiente)

Imagens dos Resultados


- Farneback



- **Horn-Schunck**



- **Lucas-Kanade:**



As imagens demonstram a segmentação em cada técnica, mostrando os clusters distintos de movimento detectados com as técnicas implementadas.

Comentários e Análises

1. Farneback:

- Bom desempenho em segmentação densa de movimento.
- Segmentou muito bem.

2. Horn-Schunck:

- Segmentação contínua e suave com boa precisão.
- Possui um desempenho computacional mais lento.
- De início recebeu muito ruído por vibração, mas ao ajustar o *threshold* de movimento a maior parte do ruído foi descartada.

3. Lucas-Kanade:

- Desempenho superior em cenas com movimentos isolados e detecções precisas.
- No entanto, apresenta alta sensibilidade ao ruído.
- Ao tentar reduzir o ruído (ajustando o *threshold* da qualidade dos pontos e o da distância mínima), observou-se a perda de movimentos sutis do objeto principal. Além disso, mesmo ao eliminar pontos de objetos que apresentaram movimento devido a pequenas vibrações no vídeo, nem todos os pontos indesejados foram corretamente descartados.